



İSTANBUL
TOPKAPI
ÜNİVERSİTESİ

FET302 – DERİN ÖĞRENME

Proje Konusu

Görüntülerden Hava Durumu Sınıflandırması

(Image-Based Weather Classification)

Ekip Adı: DEVDL

Ekip Üyeleri

- Mehmet Oytun ÖZER – 23040301043 – mehmetoytunozer@stu.topkapi.edu.tr
- Furkan Işık – 23040301063 – furkanisik1@stu.topkapi.edu.tr
- Ram İsmail – 24040301052 – ramismail@stu.topkapi.edu.tr
- Muhammet Ay – 23040301137 – muhammetay@stu.topkapi.edu.tr

PROBLEM TANIMI, MOTİVASYON VE AMAÇ

Problem Tanımı

- Hava durumu tahmini, görüntüler üzerinden çok sınıflı bir sınıflandırma problemi olarak ele alınmaktadır.
- Amaç, bir görüntünün güneşli, yağmurlu, bulutlu veya gün doğumunu sınıflarından hangisine ait olduğunu otomatik olarak belirlemektir.
- Problem, görsel verilerden anlamlı özniteliklerin çıkarılmasını ve doğru sınıflandırılmasını gerektirmektedir.

Motivasyon

- Geleneksel hava durumu tahmin sistemleri genellikle sensör ve radar altyapılarına dayanmaktadır.
- Bu altyapılar maliyetli olup her bölgede veya her senaryoda kullanılamamaktadır.
- Buna karşın, kamera görüntülerini ve paylaşılan fotoğraflar gibi görsel veriler yaygın ve erişilebilirdir.
- Bu durum, görsel tabanlı hava durumu analizini cazip bir alternatif haline getirmektedir.

AMAÇ

- Yalnızca görüntülerden faydalananarak hava durumunu tahmin edebilen bir derin öğrenme modeli geliştirmek.
- Farklı CNN ve Transfer Learning mimarilerini karşılaştırarak en başarılı yaklaşımı belirlemek.
- Geliştirilen sistemi accuracy, precision, recall ve F1-score metrikleri ile değerlendirmek.

VERİ SETİ VE BAŞARI KRİTERLERİ

- Projede kullanılacak temel veri kümesi Multiclass Weather Dataset (Kaggle)'tir.
- Görseller, farklı hava koşulları, ışıklandırma ve çevresel şartlar altında çekilmiştir.
- Bu çeşitlilik, eğitilen modelin genelleme yeteneğini test etmek için gerçekçi bir zemin sunmaktadır.

Veri seti 4 sınıf içermektedir:

- Sunny, Rainy, Cloudy, Sunrise
- Görseller RGB formatında olup, model eğitimine uygun olacak şekilde yeniden boyutlandırılmıştır.
- Ön İşleme ve Bölünme
- Görseller sabit bir giriş boyutuna ölçeklendirilmiştir.

Veri bölünmesi:

- %80 Eğitim (Train)
- %10 Doğrulama (Validation)
- %10 Test

Nicel Hedefler:

- Accuracy ≥ 0.85 -- F1-Score ≥ 0.80

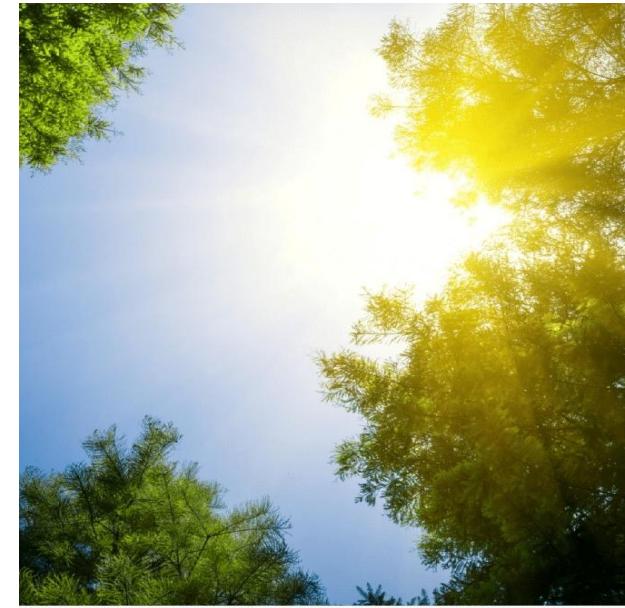
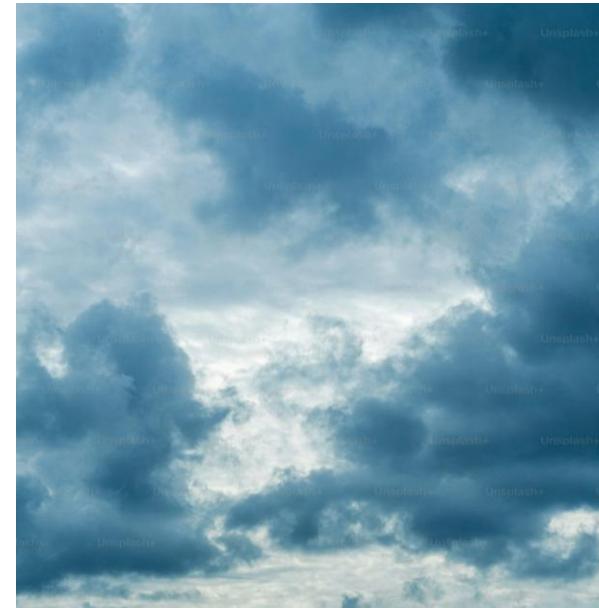
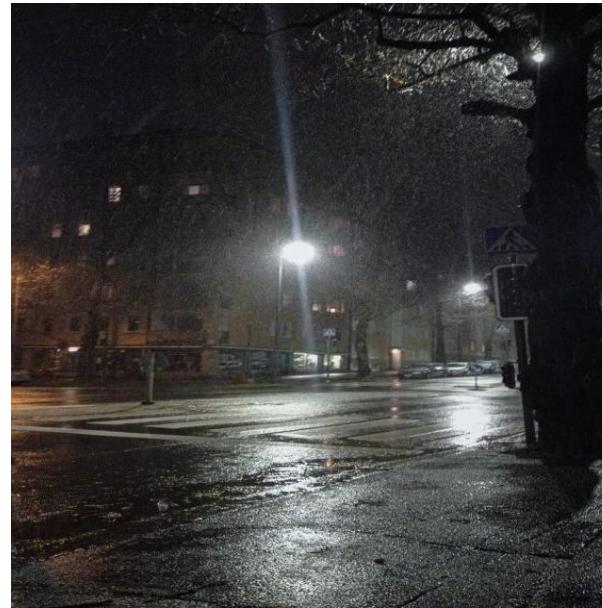
Temel Değerlendirme Metrikleri:

Accuracy, Precision, Recall, F1-Score

Veri Seti Linki

<https://www.kaggle.com/datasets/pratik2901/multiclass-weather-dataset>

Veri Setinden Bazı Örnekler



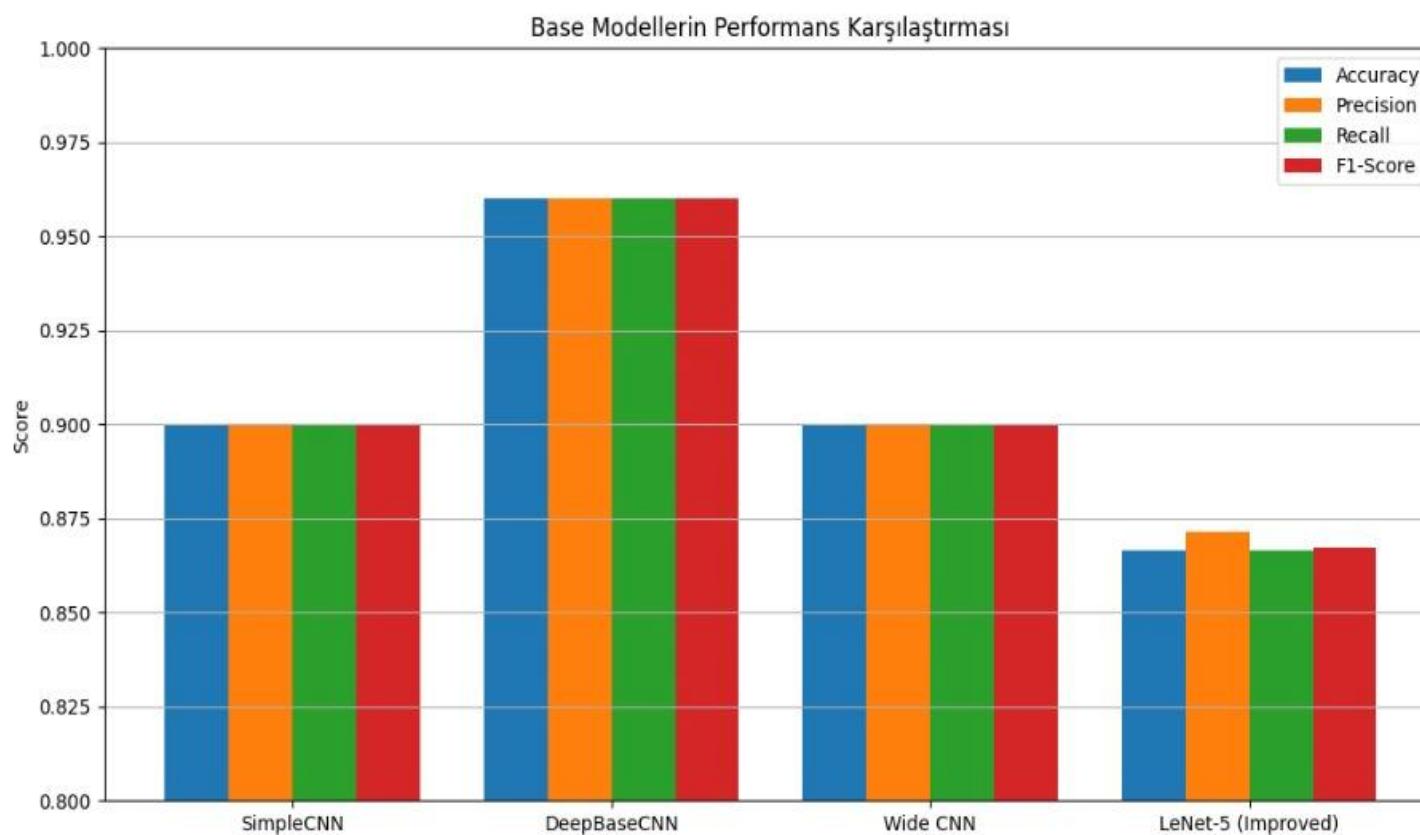
BASE MODELLER

İlk Aşama: Base Modeller

- Projenin ilk aşamasında, problemi daha iyi anlamak ve bir temel performans çizgisi (baseline) oluşturmak amacıyla dört farklı base model geliştirilmiştir.
- Her ekip üyesi, vize döneminde geliştirdiği kendi temel CNN mimarisi üzerinde çalışmış ve belirli hiperparametrelerin model performansı üzerindeki etkisini incelemiştir.
- Yapılan deneyler sonucunda, tüm base modellerin hava durumu sınıflandırma probleminde tatmin edici performanslar elde ettiği gözlemlenmiştir.
- Özellikle DeepBaseCNN modeli, diğer base modellere kıyasla daha yüksek doğruluk ve F1-score değerleri elde ederek öne çıkmıştır.
- Bu aşamada elde edilen sonuçlar, projenin ilerleyen sahalarında kullanılan transfer learning tabanlı gelişmiş modeller için güçlü bir karşılaştırma noktası oluşturmuştur.

Base modeller arasında DeepBaseCNN, tüm performans metriklerinde en yüksek başarıyı göstermiştir. SimpleCNN ve Wide CNN modelleri benzer doğruluk değerlerine sahipken, LeNet-5 (Improved) modeli daha sade mimarisine rağmen kabul edilebilir bir performans sunmuştur.

	Model	Accuracy	Precision	Recall	F1-Score
0	SimpleCNN	0.9000	0.9000	0.9000	0.9000
1	DeepBaseCNN	0.9600	0.9600	0.9600	0.9600
2	Wide CNN	0.9000	0.9000	0.9000	0.9000
3	LeNet-5 (Improved)	0.8667	0.8714	0.8667	0.8671



GELİŞMİŞ MODELLER

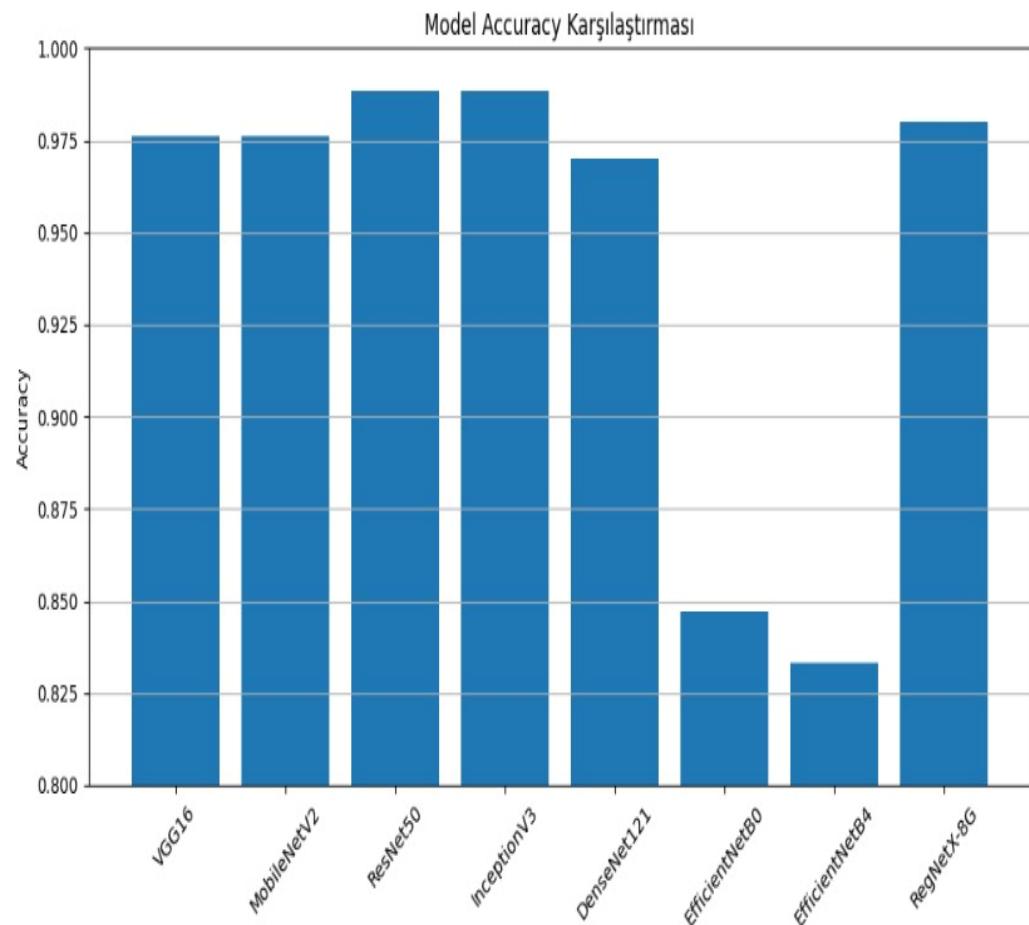
İkinci Aşama: Gelişmiş Modeller

- İkinci aşamada, hava durumu sınıflandırma problemi için güçlü ve modern CNN mimarileri kullanılmıştır.
- Bu aşamada kullanılan tüm modeller, ImageNet veri seti üzerinde önceden eğitilmiş ağırlıklarla başlatılmıştır.
- Böylece modellerin temel görsel özellikleri sıfırdan öğrenmesi yerine, mevcut bilgilerini hava durumu görsellerine uyarlaması sağlanmıştır.
- Tüm gelişmiş modeller, ortak bir eğitim ve değerlendirme çerçevesi altında karşılaştırılmıştır.

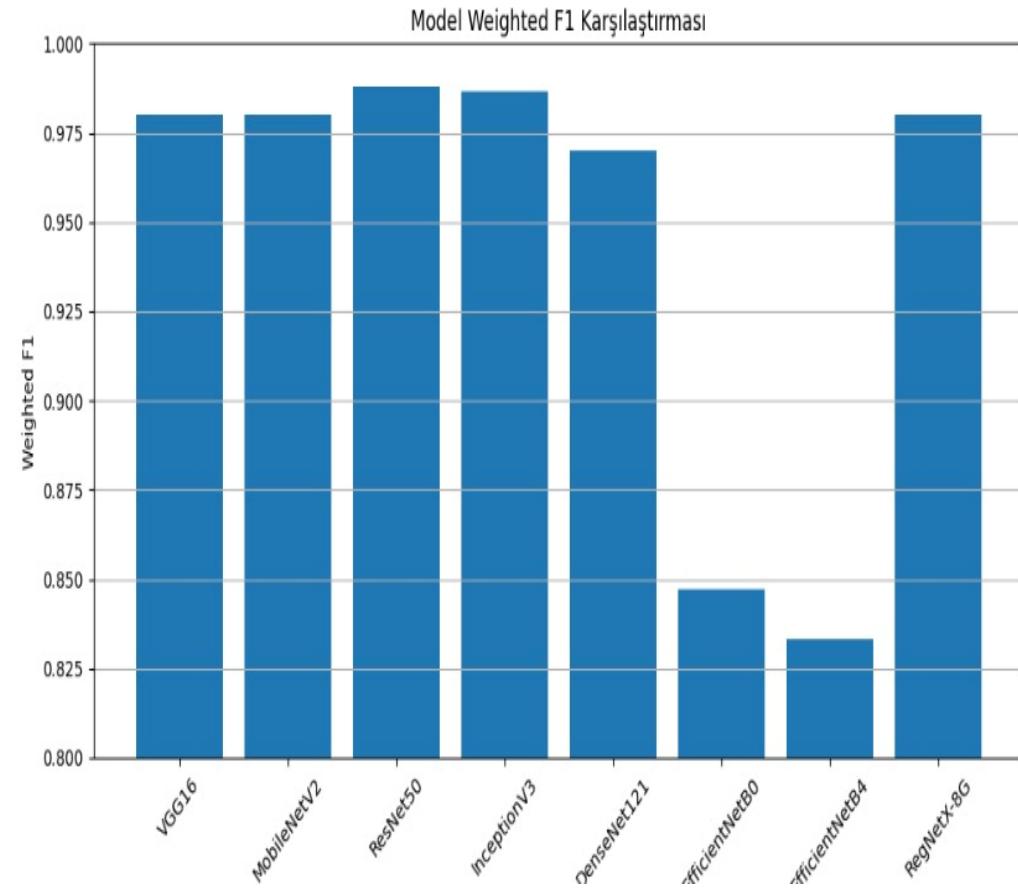
Kullanılan Gelişmiş Derin Öğrenme Modelleri

	Model	Model Türü
0	VGG16	CNN
1	ResNet50	Residual CNN
2	DenseNet121	Dense CNN
3	MobileNetV2	Lightweight CNN
4	EfficientNetB0	Efficient CNN
5	EfficientNetB4	Efficient CNN
6	RegNetX-8GF	Regularized CNN
7	InceptionV3	Multi-Scale CNN

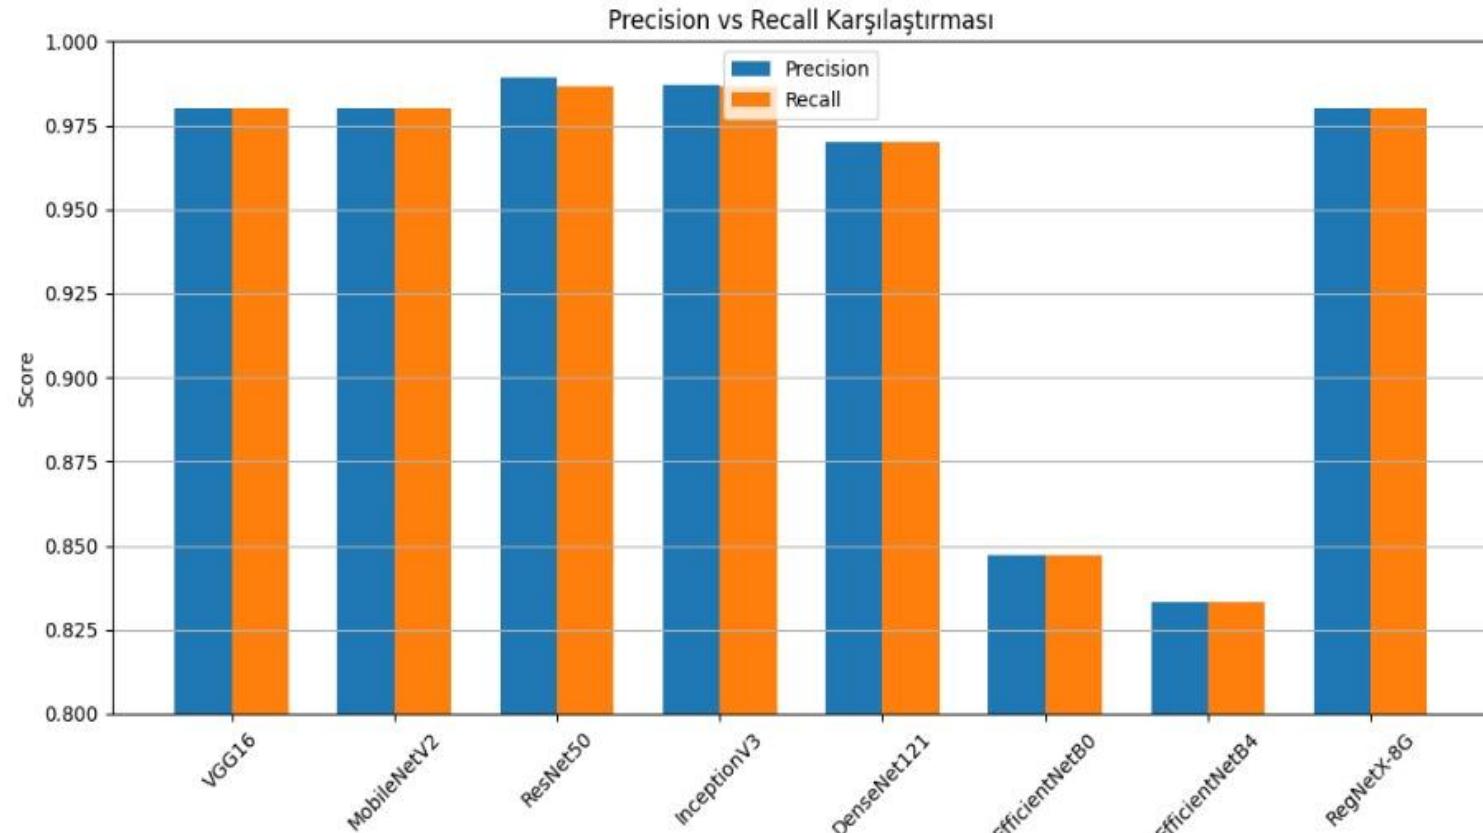
Accuracy Karşılaştırması



Weighted F1-Score Karşılaştırması



Grafik sonuçları incelendiğinde, ResNet50 ve InceptionV3 modellerinin en yüksek doğruluk değerlerine ulaştığı görülmektedir. RegNetX-8G modeli ise yüksek ve dengeli Precision, Recall ve F1 değerleriyle istikrarlı bir performans sergilemiştir. EfficientNetB0 ve EfficientNetB4 modelleri, daha düşük karmaşıklık seviyelerine rağmen kabul edilebilir performans sunmuştur.



	Model	Accuracy	F1	Precision	Recall
0	VGG16	0.9760	0.9800	0.9800	0.9800
1	MobileNetV2	0.9763	0.9800	0.9800	0.9800
2	ResNet50	0.9882	0.9878	0.9894	0.9868
3	InceptionV3	0.9882	0.9866	0.9870	0.9868
4	DenseNet121	0.9700	0.9700	0.9700	0.9700
5	EfficientNetB0	0.8472	0.8470	0.8470	0.8470
6	EfficientNetB4	0.8333	0.8330	0.8330	0.8330
7	RegNetX-8G	0.9800	0.9800	0.9800	0.9800



En Yüksek Performans Gösteren Modeller

ResNet50

%98.82

Özellik: Residual (skip) bağlantıları derin ağlarda öğrenmeyi kolaylaştırır.

InceptionV3

%98.82

Özellik: Çok ölçekli (multi-scale) özellik çıkarımı için Inception blokları kullanır.

RegNetX-8G

%98.00

Özellik: Düzenli ağ tasarımlıyla ölçeklenebilir ve dengeli performans sunar.

DevDL Çalışmasının Anlamı ve Gelecek Adımlar

Neden Önemli / Neden Heyecan Verici?

Bu çalışma, yalnızca görsel veriler kullanılarak hava durumu sınıflandırmasının yüksek doğrulukla gerçekleştirilebileceğini göstermektedir.

Farklı mimarilerin aynı veri seti üzerinde karşılaştırılması, özellikle derin öğrenme tabanlı transfer learning yaklaşımlarının gerçek dünya problemlerinde ne kadar etkili olduğunu ortaya koymuştur.

MobilNetV2 ve EfficientNet gibi hafif mimarilerin, daha büyük modellere yakın performans göstermesi, gerçek zamanlı ve mobil uygulamalar için önemli bir potansiyel sunmaktadır

Gelecek Adımlar

En başarılı modellerin gerçek zamanlı video akışları üzerinde test edilmesi.

Sınıflandırma probleminin zaman serisi ve ardışık kareler ile desteklenerek daha kararlı hale getirilmesi.

Model çıktılarının mobil veya web tabanlı bir arayüz ile son kullanıcıya sunulması.

Veri setinin genişletilerek farklı mevsimler, ışık koşulları ve kamera açılarıyla modelin genelleme yeteneğinin artırılması.

Model sıkıştırma (quantization, pruning) yöntemleri ile daha düşük donanım maliyeti hedeflenmesi.